INSTITUCIÓN UNIVERSITARIA DIGITAL DE ANTIOQUIA

Proyecto Integrado III — Analítica de Datos

Análisis descriptivo de la demanda horaria de bicicletas públicas en Washington D. C. (2011-2012)

Ideación, diseño y documentación de la necesidad — Etapa 1 del proyecto integrador

Integrantes	Carlos Andrés Osorio Agudelo Estefanía Martínez Guzmán Valentina Pérez Flórez
Grupo	AE_Grupo 3
Asignatura	Proyecto Integrado III - Analítica de Datos
Docente	Andrés Felipe Callejas Jaramillo
Institución	Institución Universitaria Digital de Antioquia
Fecha	Octubre de 2026

Tabla de contenido

Las páginas indicadas corresponden a este documento en formato PDF.

Índice de tablas.....3
1. Introducción.....4
2. Planteamiento de la necesidad.....4
3. Justificación.....5
4. Objetivos.....5
5. Marco teórico inicial.....6
6. Metodología de la etapa 1.....7
7. Reconocimiento del dataset.....10
8. Referencias.....11

Índice de tablas

En esta entrega se incluyen únicamente las tablas propias de la etapa 1. Las gráficas y las tablas de resultados se incorporarán en las etapas 2 y 3 del proyecto; por esa razón todavía no existe índice de gráficas ni de ilustraciones.

- Tabla 1. Ficha del dataset seleccionado
- Tabla 2. Diccionario inicial de variables
- Tabla 3. Relación entre la pregunta de análisis y las variables disponibles
- Tabla 4. Evidencias de la etapa 1 y su ubicación en el repositorio

1. Introducción

Los sistemas de bicicleta pública de tercera generación registran de forma automática cada préstamo y cada devolución. Esa operación continua produce un flujo de datos que describe la movilidad de una ciudad hora por hora, y que puede usarse para comprender cuándo, cómo y bajo qué condiciones se utiliza el sistema.

El proyecto parte de un dataset público obtenido desde Hugging Face: el histórico horario del sistema Capital Bikeshare de Washington D. C., publicado originalmente por el repositorio de aprendizaje automático de la Universidad de California en Irvine (UCI) y documentado por Fanaee-T y Gama (2013). El conjunto contiene 17.379 registros horarios correspondientes a los años 2011 y 2012, con la cantidad de bicicletas rentadas y las condiciones climáticas y calendáricas de cada hora.

Esta primera etapa no presenta resultados analíticos. Su propósito es definir con precisión qué información falta, para quién resultaría útil y por qué los datos seleccionados permiten obtenerla. El documento desarrolla la necesidad, la pregunta de análisis, los objetivos, la justificación, el marco conceptual mínimo, la metodología de la etapa y el reconocimiento del dataset. El análisis descriptivo propiamente dicho corresponde a las etapas siguientes del proyecto integrador.

2. Planteamiento de la necesidad

2.1. Contexto y beneficiario

El sistema de bicicleta pública opera con una flota limitada y una capacidad de estaciones que no puede ajustarse de un momento a otro. Quien planea la operación necesita anticipar en qué momentos del día y bajo qué condiciones se concentra la demanda, porque de ello dependen decisiones como el número de bicicletas disponibles por zona, la cantidad de personal de redistribución y el mantenimiento programado.

El beneficiario propuesto es el área de operaciones y planeación de un sistema de bicicletas públicas compartidas. Lo que hoy falta no son los datos —el operador los genera a diario— sino una comparación organizada que permita leer ese volumen de registros y extraer un perfil de demanda.

2.2. Necesidad de información

Se requiere conocer cómo se distribuye la demanda de bicicletas a lo largo del día y cómo cambia según el tipo de día, la temporada y la condición climática, distinguiendo además el comportamiento de los usuarios ocasionales del de los usuarios con suscripción. Con esa información, la operación podría dimensionar mejor sus recursos en las franjas de mayor presión y reconocer los periodos de baja utilización.

Es importante precisar el origen de esta necesidad: se trata de una necesidad propuesta a partir de las variables disponibles, no de un problema observado y verificado por el equipo. No se parte de afirmar que la demanda ha caído ni que existe un desequilibrio en la flota; esas afirmaciones tendrían que comprobarse con los datos, y su verificación es justamente parte del análisis posterior.

2.3. Pregunta de análisis

> *¿Cómo se distribuye la demanda horaria de bicicletas del sistema Capital Bikeshare de Washington D. C. durante 2011 y 2012 según la franja horaria, el tipo de día, la temporada y la condición climática, y qué diferencia existe entre los usuarios casuales y los registrados?*

La pregunta es descriptiva y comparativa: no busca explicar causas ni predecir valores futuros, sino caracterizar el comportamiento observado de la demanda con las variables que el dataset contiene.

2.4. Escenario de uso

El escenario es hipotético. El equipo no tiene vínculo con Capital Bikeshare ni acceso a su operación; el caso se plantea a partir de datos públicos del sistema. Un analista del área de operaciones recibe el informe descriptivo y lo usa en dos momentos: en la planeación semanal, para ajustar la disponibilidad de bicicletas en las franjas de mayor demanda, y en las reuniones periódicas con el área comercial, para evaluar el peso relativo de los usuarios ocasionales frente a los suscritos.

3. Justificación

Contar con una caracterización ordenada de la demanda permite a la operación apoyar sus decisiones en evidencia y no solo en la intuición del día a día. Hoy los registros existen, pero comparar franjas horarias, temporadas o condiciones climáticas exige un trabajo de preparación y agregación que nadie hace de forma sistemática. El aporte del proyecto es precisamente esa comparación organizada y reproducible.

El valor del análisis es descriptivo y probatorio: permite afirmar qué ocurrió en el periodo observado y con qué magnitud. No permite asegurar que una medida operativa vaya a aumentar o reducir la demanda; para eso haría falta un diseño causal o un experimento, que quedan fuera del alcance del proyecto.

Los datos seleccionados permiten abordar la necesidad porque reúnen, en una sola tabla, la cantidad de bicicletas rentadas por hora junto con variables de tiempo (hora, día de la semana, mes, temporada, año), de contexto (condición climática, temperatura, humedad, viento) y de tipo de usuario (casual y registrado). Es decir, contiene tanto la cantidad que se quiere describir como los grupos y periodos con los que se quiere comparar. Además, son datos reales, públicos y con licencia documentada, lo que hace verificables los resultados.

4. Objetivos

4.1. Objetivo general

Caracterizar descriptivamente la demanda horaria de bicicletas del sistema Capital Bikeshare de Washington D. C. durante los años 2011 y 2012, mediante indicadores y comparaciones por franja horaria, tipo de día, temporada y condición climática, para aportar evidencia que apoye las decisiones de operación del sistema.

4.2. Objetivos específicos

- Documentar la necesidad de información, la pregunta de análisis, el alcance y las limitaciones del dataset seleccionado.
- Describir la composición y la calidad del dataset: unidad de análisis, volumen de registros, tipos de variables y presencia de valores faltantes.
- Comparar la demanda promedio según franja horaria y tipo de día, distinguiendo días laborables de fines de semana y festivos.
- Comparar la demanda según temporada del año y condición climática, e identificar los niveles de menor y mayor utilización.
- Contrastar el peso de los usuarios casuales y de los registrados dentro del total de rentas, para describir los dos perfiles de uso del sistema.

5. Marco teórico inicial

5.1. Analítica descriptiva

La analítica descriptiva resume lo que ya ocurrió en un conjunto de datos históricos. Responde preguntas del tipo cuánto, cuándo y cuál, mediante conteos, promedios, porcentajes y comparaciones entre grupos (Provost y Fawcett, 2013). Se distingue de la analítica predictiva, que estima valores futuros, y de la inferencia causal, que busca atribuir un efecto a una intervención. Este proyecto se ubica exclusivamente en el primer nivel: no se construyen modelos predictivos ni se atribuyen causas.

5.2. Datos agregados y unidad de análisis

Un conjunto de datos agregado agrupa los eventos individuales en un periodo o en una unidad geográfica. En este caso, cada registro resume todas las rentas ocurridas durante una hora en el conjunto del sistema. La consecuencia metodológica es directa: no es posible analizar viajes individuales, usuarios particulares ni recorridos entre estaciones, porque esa información ya fue resumida. Confundir la unidad de análisis es el error más frecuente con datos agregados; aquí se trabaja siempre sobre horas, nunca sobre personas.

5.3. Indicadores descriptivos

Los indicadores previstos son conteos (número de horas registradas), medidas de tendencia central (media y mediana), medidas de dispersión (desviación estándar, mínimo y máximo) y proporciones. Dos de ellos se definen formalmente porque se usarán en las etapas siguientes:

- Participación de un grupo = (rentas del grupo ÷ rentas totales) × 100. Expresa el peso relativo de una categoría sobre el total.
- Variación relativa entre periodos = ((valor del periodo actual − valor del periodo anterior) ÷ valor del periodo anterior) × 100. Solo se aplica cuando el periodo anterior existe y su valor no es cero.

Como la variable principal es un conteo de eventos por hora, su distribución es asimétrica: existen muchas horas con pocas rentas y pocas horas con valores muy altos. Por esa razón, junto con la media se reportará siempre la mediana y los cuantiles, que describen mejor el comportamiento típico.

5.4. Sistemas de bicicleta pública y datos de movilidad

Los sistemas de bicicleta pública automatizan el préstamo, la devolución y el cobro, y a diferencia del transporte público tradicional registran el momento exacto de cada uso. Fanaee-T y Gama (2013) señalan que esa característica convierte al sistema en una suerte de red de sensores que describe la movilidad de la ciudad. Para este proyecto, esa propiedad es la que hace posible observar patrones horarios y estacionales en lugar de simples totales diarios.

5.5. Calidad de datos

Antes de interpretar cualquier indicador es necesario revisar la calidad del conjunto: valores faltantes, registros duplicados, tipos de dato consistentes y cobertura del periodo. Cuando un registro falta, reemplazarlo por cero sin justificación altera los promedios; cuando un dato viene codificado —por ejemplo, una temporada como un número del 1 al 4—, su significado debe tomarse de la documentación del dataset y no deducirse de los valores observados.

6. Metodología de la etapa 1

6.1. Enfoque

El enfoque es cuantitativo, descriptivo y no experimental. Se trabaja con datos secundarios de acceso público, observados sin intervención sobre el sistema. No hay manipulación de variables ni asignación de tratamientos, por lo que el estudio no permite establecer relaciones de causa y efecto.

6.2. Selección y ficha del dataset

La búsqueda se realizó en el catálogo de Hugging Face aplicando cuatro criterios: estructura tabular convertible a DataFrame, licencia declarada, tamaño procesable con los recursos del equipo y presencia de variables numéricas junto con variables categóricas de comparación. Se descartaron los conjuntos de datos sintéticos y los que solo contenían texto libre, porque dificultan una comparación cuantitativa.

Tabla 1. Ficha del dataset seleccionado

Campo	Valor
Identificador	t22000t/bike-sharing-tabular
Enlace	https://huggingface.co/datasets/t22000t/bike-sharing-tabular
Origen de los datos	UCI Machine Learning Repository, "Bike Sharing Dataset" (id 275)
Autores	Hadi Fanaee-T y Joao Gama
Año de publicación	2013
Licencia	CC BY 4.0 (declarada en la ficha de Hugging Face); el dataset original solicita citar el artículo de los autores
Formato	CSV
Registros	17.379 filas y 17 columnas
Periodo cubierto	1 de enero de 2011 a 31 de diciembre de 2012
Granularidad	Horaria (731 días con registros)
Idioma	Inglés (encabezados de columna)
Datos sintéticos	No. Son registros reales anonimizados del sistema Capital Bikeshare

Split utilizado	train (es la única división publicada)
Fecha de consulta	24 de octubre de 2026

Nota. Elaboración propia con la información de la ficha del dataset y del README oficial de UCI.

6.3. Unidad de análisis

La unidad de análisis es la hora de operación del sistema completo. Cada fila representa una hora de un día determinado, con el total de rentas de esa hora. No es una persona, ni una bicicleta, ni una estación, ni un viaje individual. La población observada corresponde al conjunto de las horas registradas del sistema en Washington D. C. durante los dos años mencionados.

6.4. Diccionario inicial de variables

Los significados se tomaron del README oficial del dataset en UCI, no se dedujeron de los datos. Ninguna variable quedó sin documentar, por lo que no hay significados pendientes de verificar.

Tabla 2. Diccionario inicial de variables

Variable	Tipo de dato	Unidad / valores	Significado y regla
instant	Entero	1 a 17.379	Índice del registro
dteday	Fecha	AAAA-MM-DD	Fecha del registro
season	Entero (categórica)	1 a 4	Temporada: 1 primavera, 2 verano, 3 otoño, 4 invierno
yr	Entero (categórica)	0 o 1	Año: 0 = 2011, 1 = 2012
mnth	Entero	1 a 12	Mes del año
hr	Entero	0 a 23	Hora del día
holiday	Entero (binaria)	0 o 1	Indica si el día es festivo
weekday	Entero (categórica)	0 a 6	Día de la semana (0 = domingo ... 6 = sábado)
workingday	Entero (binaria)	0 o 1	1 si el día no es fin de semana ni festivo; 0 en caso contrario
weathersit	Entero (categórica)	1 a 4	Condición climática: 1 despejado o parcialmente nublado, 2 neblina o nublado, 3 lluvia o nieve ligera, 4 lluvia fuerte o tormenta
temp	Decimal	Normalizado	Temperatura en °C dividida entre 41 (máximo)
atemp	Decimal	Normalizado	Sensación térmica en °C dividida entre 50 (máximo)
hum	Decimal	Normalizado	Humedad relativa dividida entre 100 (máximo)
windspeed	Decimal	Normalizado	Velocidad del viento dividida entre 67 (máximo)
casual	Entero	Rentas por hora	Cantidad de usuarios ocasionales (sin suscripción)
registered	Entero	Rentas por hora	Cantidad de usuarios con suscripción
cnt	Entero	1 a 977	Total de rentas de la hora; equivale a casual +

			registered

Nota. Significados tomados del README oficial del dataset (UCI) y de la ficha de Hugging Face. Las variables normalizadas se pueden devolver a su escala original multiplicando por el valor máximo indicado.

6.5. Diseño inicial del análisis

El diseño previsto organiza las variables en función de la pregunta planteada. Cada bloque de variables responde a una parte de la pregunta y produce un indicador descriptivo concreto.

Tabla 3. Relación entre la pregunta de análisis y las variables disponibles

Aspecto de la pregunta	Variables que lo permiten	Indicador previsto
¿Cuánta demanda hay?	cnt	Total, promedio y mediana de rentas por hora
¿En qué franjas horarias?	hr	Promedio de rentas por hora del día
¿Depende del tipo de día?	workingday, holiday, weekday	Promedio de rentas en días laborables frente a no laborables
¿Cambia con la temporada?	season, mnth, yr	Promedio de rentas por temporada y comparación entre 2011 y 2012
¿Depende del clima?	weathersit, temp, hum, windspeed	Promedio de rentas por condición climática y por rangos de temperatura
¿Quiénes usan el sistema?	casual, registered	Participación porcentual de cada tipo de usuario

Nota. Elaboración propia. Los indicadores se calcularán en la etapa 3 del proyecto.

6.6. Alcance y limitaciones

El análisis cubre el sistema Capital Bikeshare de Washington D. C. entre 2011 y 2012, con la hora de operación como unidad de análisis. Sus principales limitaciones son:

- Los datos corresponden a una sola ciudad y a dos años. No permiten generalizar a otras ciudades ni afirmar nada sobre años posteriores a 2012.
- Al estar agregados por hora, no contienen información de personas, trayectos, estaciones de origen y destino, ni duración de los viajes.
- No hay información de disponibilidad de bicicletas, capacidad de las estaciones, precios ni condiciones de mantenimiento, de modo que no se puede describir la oferta ni la rentabilidad.
- La condición climática del nivel 4 (lluvia fuerte o tormenta) aparece en muy pocos registros, por lo que cualquier promedio de ese nivel debe interpretarse con cautela.
- La comparación entre años está afectada por cambios en el propio sistema durante el periodo, que los datos no documentan.

6.7. Reproducibilidad y herramientas

El trabajo se desarrolló con Python y la librería pandas (McKinney, 2010). El repositorio del proyecto contiene dos clases reutilizables que se emplean en todos los notebooks: HFDatasetLoader, que obtiene el dataset desde Hugging Face y devuelve un DataFrame, y DatasetSummarizer, que recibe un DataFrame y genera un resumen en un archivo de texto. El notebook de esta etapa usa ambas clases en ese orden, de modo que cualquiera puede repetir la obtención de los datos y verificar el resumen generado.

Tabla 4. Evidencias de la etapa 1 y su ubicación en el repositorio

Evidencia	Contenido	Ruta en el repositorio
Clase de carga	HFDatasetLoader: obtiene el dataset desde Hugging Face y devuelve un DataFrame	src/clases_po/hf_loader.py
Clase de resumen	DatasetSummarizer: resume el DataFrame y lo exporta a .txt	src/clases_po/summarizer.py
Notebook de la etapa	Carga, reconocimiento del dataset y generación del resumen	AE2/notebooks/ EA2_reconocimiento_dataset.ipynb
Resumen automático	Archivo .txt generado por código desde el DataFrame	AE2/resultados/ resumen_dataframe.txt
Documento	Este informe en formato .docx y .pdf	AE2/documento/

Nota. Repositorio: https://github.com/carlososoa/proyecto-integrado-iii

7. Reconocimiento del dataset

7.1. Qué contiene

El DataFrame obtenido tiene 17.379 filas y 17 columnas. Cubre 731 días de calendario entre el 1 de enero de 2011 y el 31 de diciembre de 2012, con registros horarios. La variable de cantidad (cnt) presenta un mínimo de 1 y un máximo de 977 rentas por hora, con una media de 189,5 y una mediana de 142: la media supera a la mediana, lo que confirma la asimetría esperada en datos de conteo y justifica reportar ambas medidas.

El conjunto no contiene valores nulos ni filas duplicadas en ninguna de sus 17 columnas. La distribución por temporada es equilibrada (entre 4.232 y 4.496 registros por estación) y la distribución por condición climática se concentra en los niveles 1 y 2 (11.413 y 4.544 registros), con apenas 3 registros de nivel 4.

Los usuarios registrados explican el 81,2 % de las rentas totales del periodo, frente al 18,8 % de los usuarios ocasionales. Se verificó además que la suma de ambas columnas coincide exactamente con el total en los 17.379 registros, lo que confirma la consistencia interna del archivo.

7.2. Calidad de los datos

La revisión inicial arrojó los siguientes hallazgos:

- No hay valores nulos ni filas duplicadas.
- El periodo completo exigiría 17.544 horas (731 días × 24 horas), pero el dataset contiene 17.379: faltan 165 horas. En 76 días hay menos de 24 registros, lo que sugiere interrupciones del servicio o ausencia de datos en determinadas horas.
- Las variables categóricas vienen codificadas numéricamente. Su significado proviene de la documentación oficial; interpretarlas sin esa referencia llevaría a conclusiones equivocadas, por ejemplo a suponer que la temporada 4 es la más calurosa cuando en realidad corresponde al invierno.
- Las variables de clima están normalizadas; una temperatura de 0,5 no significa medio grado sino aproximadamente 20,5 °C.

Estos hallazgos no invalidan el dataset: lo que hacen es fijar las reglas de preparación para la etapa siguiente, donde se reconstruirán las escalas, se traducirán los códigos y se documentará qué horas faltan antes de calcular cualquier indicador.

7.3. Cómo las variables permiten abordar la necesidad

La pregunta de análisis se puede responder íntegramente con las variables disponibles. La cantidad de rentas por hora (cnt) es la medida que se quiere describir. La hora del día (hr) permite construir las franjas horarias y comparar la demanda a lo largo de la jornada. El tipo de día se obtiene de workingday y holiday, que distinguen la movilidad cotidiana del uso de fin de semana y de festivos. La temporada y el mes aportan la comparación estacional, y el año permite contrastar los dos periodos anuales. La condición climática y las variables meteorológicas permiten agrupar las horas según el contexto ambiental. Por último, casual y registered separan los dos perfiles de usuario dentro del total.

En conjunto, el dataset contiene la variable que se desea describir y los criterios de agrupación necesarios para compararla. Esa correspondencia entre pregunta y variables es la razón por la cual se seleccionó este conjunto de datos y no otro.

8. Referencias

Fanaee-T, H. y Gama, J. (2013). Event labeling combining ensemble detectors and background knowledge. Progress in Artificial Intelligence, pp. 1-15. Springer Berlin Heidelberg. https://doi.org/10.1007/s13748-013-0040-3

Hugging Face. (2026). t22000t/bike-sharing-tabular [Dataset]. Recuperado el 24 de octubre de 2026 de https://huggingface.co/datasets/t22000t/bike-sharing-tabular

McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt y J. Millman (Eds.), Proceedings of the 9th Python in Science Conference (pp. 56-61).

Provost, F. y Fawcett, T. (2013). Data science for business: what you need to know about data mining and data-analytic thinking. O'Reilly Media.

UCI Machine Learning Repository. (s. f.). Bike Sharing Dataset (id 275). University of California, Irvine. Recuperado el 24 de octubre de 2026 de https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset

The pandas development team. (2026). pandas documentation. Recuperado el 24 de octubre de 2026 de https://pandas.pydata.org/docs/