INSTITUCIÓN UNIVERSITARIA DIGITAL DE ANTIOQUIA

Proyecto Integrado III — Analítica de Datos

Transformación y enriquecimiento de los datos de demanda horaria de bicicletas públicas en Washington D. C. (2011-2012)

Transformación, enriquecimiento y respuestas a las preguntas de negocio — Etapa 2 del proyecto integrador

Integrantes	Carlos Andrés Osorio Agudelo Estefanía Martínez Guzmán Valentina Pérez Flórez
Grupo	AE_Grupo 3
Asignatura	Proyecto Integrado III - Analítica de Datos
Docente	Andrés Felipe Callejas Jaramillo
Institución	Institución Universitaria Digital de Antioquia
Fecha	Noviembre de 2026

Tabla de contenido

Las páginas indicadas corresponden a este documento en formato PDF.

1. Introducción.....4
2. La necesidad y las preguntas de negocio.....4
2.1. Recordatorio de la necesidad.....4
2.2. Preguntas y resultados asociados.....4
3. Metodología de la etapa 2.....5
3.1. Enfoque, datos y herramientas.....5
3.2. Reglas de transformación y control de calidad.....5
3.3. Enriquecimiento.....6
3.4. Cruce con la tabla diaria y validación.....6
3.5. Procedimiento para responder cada pregunta.....7
3.6. Por qué no se requirió una fuente externa.....7
4. Diccionario de datos actualizado.....7
5. Resultados y discusión.....9
5.1. Demanda total y distribución por franja horaria.....9
5.2. Demanda según el tipo de día.....10
5.3. Temporada y comparación entre años.....10
5.4. Condición climática y temperatura.....11
5.5. Perfil de usuario.....12
5.6. Concentración de la operación y días de mayor demanda.....12
5.7. Discusión: qué dicen los resultados para la operación.....13
5.8. Limitaciones de los resultados.....13
6. Conclusiones del avance.....14
7. Referencias.....14
8. Anexo. Evidencias y rutas del repositorio.....15

Índice de tablas

Tabla 1. Relación entre las preguntas, las variables y las tablas de resultados
Tabla 2. Reglas de transformación y su efecto sobre los datos
Tabla 3. Variables incorporadas en el enriquecimiento
Tabla 4. Validación de la unión con la tabla diaria
Tabla 5. Diccionario de datos actualizado
Tabla 6. Demanda por franja horaria
Tabla 7. Horas de mayor y menor demanda promedio
Tabla 8. Demanda según el tipo de día
Tabla 9. Demanda por temporada
Tabla 10. Comparación del promedio entre 2011 y 2012
Tabla 11. Promedio de rentas por hora según temporada y año
Tabla 12. Demanda según la condición climática
Tabla 13. Demanda por rango de temperatura
Tabla 14. Composición de la demanda por tipo de usuario
Tabla 15. Tipo de usuario según el tipo de día
Tabla 16. Distribución de la participación de una hora dentro de su día
Tabla 17. Días de mayor demanda del periodo
Tabla 18. Evidencias de la etapa 2 y su ubicación en el repositorio

1. Introducción

La primera etapa del proyecto definió la necesidad de información, la pregunta de análisis y el reconocimiento del dataset. Esta segunda etapa convierte ese diseño en datos preparados: transforma el conjunto original, documenta las reglas de calidad aplicadas, incorpora variables derivadas y responde cada pregunta de negocio con una tabla de resultados.

El trabajo conserva el dataset, las preguntas y el repositorio de la etapa anterior; no se ajustó el alcance. El punto de partida son 17.379 horas de operación registradas entre el 1 de enero de 2011 y el 31 de diciembre de 2012 en el sistema Capital Bikeshare de Washington D. C., y el punto de llegada es un DataFrame de 40 columnas con las mismas filas, del que se derivan doce tablas de resultados.

El documento se organiza en seis partes: el recordatorio de la necesidad y las preguntas; la metodología de la etapa, con las reglas de transformación, el enriquecimiento y el procedimiento de análisis; el diccionario de datos actualizado; los resultados y su discusión; las conclusiones del avance; y las referencias, los índices y el anexo de evidencias.

2. La necesidad y las preguntas de negocio

2.1. Recordatorio de la necesidad

El área de operaciones de un sistema de bicicletas públicas necesita anticipar en qué momentos del día y bajo qué condiciones se concentra la demanda, porque de ello dependen la disponibilidad de bicicletas por zona, el personal de redistribución y el mantenimiento programado. El dataset no trae esa lectura hecha: la información existe, pero comparar franjas, temporadas o condiciones climáticas exige prepararla y agregarla de forma sistemática. Ese es el aporte de esta etapa.

2.2. Preguntas y resultados asociados

Las seis preguntas de la etapa anterior se mantienen y cada una queda asociada a las variables que la responden y a la tabla que la sustenta en este documento.

Tabla 1. Relación entre las preguntas, las variables y las tablas de resultados

Pregunta	Variables	Tabla
¿Cuánta demanda hay y cómo se reparte en el día?	cnt, hr, fecha_hora	6 y 7
¿En qué franjas horarias se concentra?	hr, franja_horaria	6
¿Cambia según el tipo de día?	workingday, holiday, weekday, tipo_dia	8
¿Cambia con la temporada y entre 2011 y 2012?	season, mnth, yr, anio	9, 10 y 11
¿Cambia con el clima y la temperatura?	weathersit, temp_c, hum_pct, windspeed_kmh	12 y 13
¿Qué peso tienen casuales y registrados?	casual, registered, pct_casual	14 y 15

Nota. Elaboración propia. Los números de tabla remiten a las tablas de resultados de la sección 5.

3. Metodología de la etapa 2

3.1. Enfoque, datos y herramientas

El enfoque es cuantitativo, descriptivo y no experimental. Se trabaja con datos secundarios de acceso público, observados sin intervención sobre el sistema, y la unidad de análisis sigue siendo la hora de operación: 17.379 registros horarios del sistema completo, no personas ni viajes individuales.

El procesamiento se hizo en Python con la librería pandas. La lógica quedó separada en clases reutilizables dentro del repositorio: HFDatasetLoader obtiene el dataset desde Hugging Face; TransformadorBikes aplica las reglas de calidad y registra su efecto; EnriquecedorBikes construye las variables derivadas y el cruce con la tabla diaria; y Reportes genera el archivo descriptivo en texto. El notebook de la etapa ejecuta esas clases en orden y produce todas las salidas con rutas relativas, de modo que cualquier persona pueda repetir el proceso.

3.2. Reglas de transformación y control de calidad

Antes de analizar, el conjunto se sometió a ocho controles. Cada regla quedó implementada en un método propio y reporta cuántos registros afecta; los controles que no encontraron problemas también se registran con cero. No se eliminó ningún registro ni se imputó ningún valor: cuando un dato faltaba, se documentó.

Tabla 2. Reglas de transformación y su efecto sobre los datos

Regla	Decisión aplicada	Registros afectados
Tipo de fecha	dteday pasó de str a datetime64[us]; se creó fecha_hora	17.379
Escalas	temp→°C, atemp→°C, hum→%, windspeed→km/h (4 columnas nuevas)	17.379
Códigos	5 variables categóricas traducidas a etiquetas	17.379
Tipos numéricos	11 columnas de conteo y código convertidas a entero; el dataset no trae identificadores con decimales	0
Duplicados	0 horas repetidas en fecha_hora	0
Consistencia cnt	cnt = casual + registered en los 17.379 registros	0
Cobertura	17.379 de 17.544 horas (165 faltantes en 76 días); no se imputan	0
Selección	se conservan las 17 columnas originales y los 17.379 registros: todos aportan a las preguntas	0

Nota. Elaboración propia a partir de la tabla de reglas generada por el notebook. Los controles con cero registros afectados confirman que no había duplicados, inconsistencias en el total ni identificadores con decimales.

La conversión de fechas construyó un timestamp por hora (fecha más hora) que permite ordenar la serie y detectar huecos. Las variables meteorológicas se devolvieron a su escala original multiplicando por el máximo documentado en el README de UCI: temperatura y sensación térmica

por 41 y 50, humedad por 100 y viento por 67. Los códigos de temporada, clima, día de la semana y año se tradujeron a etiquetas, conservando el código original al lado para no perder trazabilidad.

El periodo completo exigiría 24 horas por 731 días, es decir 17.544 registros; el archivo contiene 17.379, de modo que faltan 165 horas repartidas en 76 días. Esas horas no se rellenaron: un valor inventado alteraría los promedios y las participaciones. En su lugar se dejó la marca dia_completo, que identifica los días con menos de 24 registros y permite advertir la limitación en cada resultado.

3.3. Enriquecimiento

El enriquecimiento construye información nueva a partir de la que ya existe: no agrega registros ni fuentes externas. Se incorporaron doce variables, agrupadas en cuatro bloques: dimensiones de calendario, composición del usuario, rangos de clima y contexto del día. Cada una queda documentada con su fórmula y su utilidad para responder las preguntas.

Tabla 3. Variables incorporadas en el enriquecimiento

Variable	Fórmula o regla	Utilidad
mes	Nombre del mes a partir de dteday	Comparar estacionalidad
es_fin_de_semana	weekday en {0, 6} (0 = domingo)	Separar el uso de fin de semana
franja_horaria	Rangos de hr: 0-5, 6-8, 9-11, 12-15, 16-19, 20-23	Comparar la demanda a lo largo del día
es_hora_pico	franja_horaria en {Pico mañana, Pico tarde}	Identificar la presión operativa
pct_casual	casual / cnt × 100	Describir el perfil ocasional
pct_registered	registered / cnt × 100	Describir el perfil suscrito
rango_temperatura	Cortes de temp_c en 5, 15 y 25 °C	Comparar la demanda por temperatura
clima_adverso	weathersit en {3, 4}	Aislar el efecto del mal tiempo
total_dia	Suma de cnt por dteday	Contexto del día para cada hora
promedio_hora_dia	Media de cnt de las horas del día	Comparar la hora con un día típico
horas_registradas_dia	Conteo de registros del día	Identificar días incompletos
pct_hora_del_dia	cnt / total_dia × 100	Pesar la hora dentro de la operación del día

Nota. Elaboración propia. Los cortes de las franjas horarias son operativos: agrupan las horas de entrada y salida laboral y no son intervalos estadísticos.

3.4. Cruce con la tabla diaria y validación

Cuatro de las variables nuevas provienen de un cruce entre el detalle horario y un resumen por día construido con los mismos datos. La clave de relación es la fecha: la tabla diaria tiene un registro por día, por lo que la unión es de muchos a uno y no puede multiplicar las horas. Aun así se comprobó, como exige la consigna, comparando filas y total de rentas antes y después.

Tabla 4. Validación de la unión con la tabla diaria

Comprobación	Resultado
Filas antes de la unión	17.379
Filas después de la unión	17.379
Rentas antes de la unión	3.292.679
Rentas después de la unión	3.292.679
Días en la tabla diaria	731
Horas sin coincidencia	0

Nota. Elaboración propia. La igualdad en filas y rentas confirma que la unión no duplicó registros ni alteró los totales.

3.5. Procedimiento para responder cada pregunta

Cada respuesta se construye con una agrupación sobre el DataFrame enriquecido. Para las variables categóricas se agrupa por la categoría y se calculan cuatro medidas: horas registradas, rentas totales, promedio de rentas por hora y mediana. La participación se calcula sobre el total de rentas del periodo, de modo que las categorías de una misma tabla suman 100 %. Se reporta la mediana junto al promedio porque el conteo horario es asimétrico: muchas horas de baja actividad y pocas de actividad muy alta.

Las tablas se exportaron a archivos CSV desde el propio notebook y el texto descriptivo del DataFrame final se generó por código, con filas, columnas, tipos, valores nulos y estadísticas numéricas. El documento reproduce esas mismas cifras; no se transcribieron a mano.

3.6. Por qué no se requirió una fuente externa

La consigna permite enriquecer con los datos existentes y reserva las fuentes externas para cuando la necesidad lo justifique. En este proyecto no fue necesario: las 17 variables originales cubren la cantidad que se quiere describir (cnt), los grupos de comparación (hora, tipo de día, temporada, clima) y los dos perfiles de usuario. Agregar una fuente externa habría introducido una dependencia de disponibilidad y de licencia sin mejorar ninguna de las seis respuestas; además, los datos sintéticos o generados con modelos de lenguaje contradicen la condición de datos reales y verificables que sustenta el proyecto.

4. Diccionario de datos actualizado

El diccionario incorpora las variables nuevas y conserva las originales que se usan en el análisis, con su tipo, su unidad o dominio y su significado. Los significados de las variables originales provienen del README oficial del dataset en UCI; los de las nuevas, de las reglas descritas en la metodología.

Tabla 5. Diccionario de datos actualizado

Variable	Tipo	Unidad o valores	Significado y regla
dteday	Fecha	AAAA-MM-DD	Fecha del registro horario
fecha_hora	Fecha y hora	Timestamp	Fecha del día más la hora; clave temporal del análisis
hr	Entero	0 a 23	Hora del día

Variable	Tipo	Unidad o valores	Significado y regla
cnt	Entero	Rentas por hora	Total de rentas de la hora; equivale a casual + registered
casual	Entero	Rentas por hora	Rentas de usuarios sin suscripción
registered	Entero	Rentas por hora	Rentas de usuarios con suscripción
season	Entero (categórica)	1 a 4	Temporada: 1 primavera, 2 verano, 3 otoño, 4 invierno
temporada	Texto	Primavera a Invierno	Nombre de la temporada
yr	Entero (categórica)	0 o 1	Año: 0 = 2011, 1 = 2012
anio	Entero	2011 o 2012	Año en formato de cuatro dígitos
mnth	Entero	1 a 12	Mes del año
mes	Texto	Enero a Diciembre	Nombre del mes
weekday	Entero (categórica)	0 a 6	Día de la semana (0 = domingo)
dia_semana	Texto	Domingo a Sábado	Nombre del día de la semana
workingday	Entero (binaria)	0 o 1	1 si el día no es fin de semana ni festivo
holiday	Entero (binaria)	0 o 1	Indica si el día es festivo
tipo_dia	Texto	Laborable / No laborable	Clasificación a partir de workingday
es_fin_de_semana	Booleano	Verdadero / Falso	weekday en {0, 6}
weathersit	Entero (categórica)	1 a 4	Condición climática
clima	Texto	Despejado a Tormenta	Nombre de la condición climática
clima_adverso	Booleano	Verdadero / Falso	weathersit en {3, 4}
temp	Decimal	Normalizado (0-1)	Temperatura dividida entre 41
temp_c	Decimal	°C	Temperatura en grados Celsius
atemp	Decimal	Normalizado (0-1)	Sensación térmica dividida entre 50
atemp_c	Decimal	°C	Sensación térmica en grados Celsius
hum	Decimal	Normalizado (0-1)	Humedad relativa dividida entre 100
hum_pct	Decimal	%	Humedad relativa en porcentaje
windspeed	Decimal	Normalizado (0-1)	Velocidad del viento dividida entre 67
windspeed_kmh	Decimal	km/h	Velocidad del viento en kilómetros por hora
rango_temperatura	Texto (ordinal)	Cuatro rangos	Cortes en 5, 15 y 25 °C

Variable	Tipo	Unidad o valores	Significado y regla
franja_horaria	Texto (ordinal)	Seis franjas	Madrugada, pico mañana, mañana, mediodía, pico tarde, noche
es_hora_pico	Booleano	Verdadero / Falso	Pertenencia a los dos picos de movilidad
pct_casual	Decimal	%	casual / cnt × 100
pct_registered	Decimal	%	registered / cnt × 100
total_dia	Entero	Rentas por día	Suma de cnt del día
promedio_hora_dia	Decimal	Rentas por hora	Media de cnt de las horas registradas del día
horas_registradas_dia	Entero	Horas	Número de registros del día
pct_hora_del_dia	Decimal	%	cnt / total_dia × 100
dia_completo	Booleano	Verdadero / Falso	El día tiene las 24 horas registradas

Nota. Elaboración propia a partir del README oficial del dataset (UCI, id 275) y de las reglas de transformación y enriquecimiento descritas en la sección 3.

5. Resultados y discusión

En el periodo se registraron 3.292.679 rentas en 17.379 horas, con un promedio de 189,5 rentas por hora y una mediana de 142. La diferencia entre promedio y mediana ya anticipa lo que muestran las tablas: la distribución es asimétrica y se concentra en pocas horas del día. Los resultados se presentan en el orden de las preguntas de la sección 2.

5.1. Demanda total y distribución por franja horaria

La franja de pico de la tarde concentra un tercio de la demanda ocupando una sexta parte de las horas registradas. La madrugada, en cambio, aporta una fracción mínima aunque ocupa la mayor cantidad de horas del archivo. Esa concentración es la que justifica dimensionar la operación por franjas y no por el promedio del día.

Tabla 6. Demanda por franja horaria

Franja	Horas	Rentas	Promedio	Mediana	Participación
Pico tarde	2.916	1.101.169	377,6	361	33,4 %
Mediodía	2.915	728.134	249,8	222	22,1 %
Pico mañana	2.179	470.304	215,8	131	14,3 %
Noche	2.912	449.548	154,4	136	13,7 %
Mañana	2.181	437.015	200,4	184	13,3 %
Madrugada	4.276	106.509	24,9	13	3,2 %
Total	17.379	3.292.679	189,5	142	100,0 %

Nota. Elaboración propia. Promedio y mediana en rentas por hora; participación sobre el total de rentas del periodo.

Al mirar las horas individuales, la demanda sube con la jornada laboral y tiene dos picos: uno en la mañana, asociado a la entrada al trabajo, y otro más alto en la tarde, asociado a la salida. La hora 17

es la de mayor promedio del periodo y la hora 4 la de menor. La tabla siguiente muestra los extremos.

Tabla 7. Horas de mayor y menor demanda promedio

Hora	Promedio	Mediana	Rentas	Participación
17:00	461,5	475,0	336.860	10,2 %
18:00	425,5	418,5	309.772	9,4 %
8:00	359,0	385,0	261.001	7,9 %
16:00	312,0	304,5	227.748	6,9 %
3:00	11,7	6,0	8.174	0,2 %
4:00	6,4	6,0	4.428	0,1 %

Nota. Elaboración propia. Las cuatro primeras filas son las horas de mayor promedio y las dos últimas, las de menor.

5.2. Demanda según el tipo de día

Los días laborables aportan cerca del 70 % de las rentas y un promedio apenas superior al de los días no laborables. La diferencia de promedios es pequeña, pero la mediana sí cambia: el día no laborable tiene muchas horas de baja actividad y unas pocas muy altas, de modo que su promedio se acerca al laborable mientras su comportamiento típico es menor. Esa diferencia entre promedio y mediana es un hallazgo en sí mismo y anticipa la composición de usuario que se analiza más adelante.

Tabla 8. Demanda según el tipo de día

Tipo de día	Horas	Rentas	Promedio	Mediana	Participación	Casual
Laborable	11.865	2.292.410	193,2	151	69,6 %	13,2 %
No laborable	5.514	1.000.269	181,4	119	30,4 %	31,7 %

Nota. Elaboración propia. La última columna es la participación del usuario casual dentro del tipo de día.

5.3. Temporada y comparación entre años

El otoño es la temporada de mayor demanda promedio y la primavera la más baja: su promedio es menos de la mitad del otoño, aunque la cantidad de horas registradas es similar en las cuatro temporadas. La diferencia no se explica por la cobertura, sino por el comportamiento de la demanda.

Tabla 9. Demanda por temporada

Temporada	Horas	Rentas	Promedio	Participación
Otoño	4.496	1.061.129	236,0	32,2 %
Verano	4.409	918.589	208,3	27,9 %
Invierno	4.232	841.613	198,9	25,6 %
Primavera	4.242	471.348	111,1	14,3 %

Nota. Elaboración propia. Promedio en rentas por hora.

Entre años, el promedio de 2012 es notablemente superior al de 2011. Esa diferencia mezcla el crecimiento del propio sistema con la estacionalidad y con la composición de meses de cada archivo,

así que no se puede leer como un efecto del año. La comparación por temporada dentro de cada año reduce parcialmente ese problema, pero no lo elimina: en las cuatro temporadas el promedio de 2012 es mayor, lo que sugiere un crecimiento sostenido del sistema más que un cambio de estacionalidad.

Tabla 10. Comparación del promedio entre 2011 y 2012

Año	Horas	Rentas	Promedio	Participación
2011	8.645	1.243.103	143,8	37,8 %
2012	8.734	2.049.576	234,7	62,2 %

Nota. Elaboración propia. Promedio en rentas por hora.

Tabla 11. Promedio de rentas por hora según temporada y año

Temporada	2011	2012	Variación
Otoño	187,3	284,3	51,8 %
Verano	157,7	259,0	64,2 %
Invierno	152,8	245,7	60,8 %
Primavera	72,5	147,8	103,9 %

Nota. Elaboración propia. Variación relativa del promedio entre un año y otro.

5.4. Condición climática y temperatura

El clima separa con claridad los niveles de demanda: con cielo despejado el promedio supera los 200 viajes por hora y con lluvia o nieve ligera baja a poco más de la mitad. El nivel de tormenta aparece en muy pocas horas, de modo que su promedio no es representativo y se reporta solo para dejar constancia de que existe en el archivo.

Tabla 12. Demanda según la condición climática

Condición	Horas	Rentas	Promedio	Mediana	Participación
Despejado	11.413	2.338.173	204,9	159	71,0 %
Neblina o nublado	4.544	795.952	175,2	133	24,2 %
Lluvia o nieve ligera	1.419	158.331	111,6	63	4,8 %
Lluvia fuerte o tormenta	3	223	74,3	36	0,0 %

Nota. Elaboración propia. La condición de tormenta tiene tres registros: su promedio no es representativo.

La temperatura muestra una relación monótona: a mayor rango, mayor demanda promedio. El salto entre el rango templado y el cálido es el más grande de la serie, lo que sugiere que la demanda no depende solo de que no llueva, sino de que haga una temperatura agradable para desplazarse. Como en el resto del análisis, se describe la asociación observada, no una relación causal.

Tabla 13. Demanda por rango de temperatura

Rango	Horas	Rentas	Promedio	Mediana
Fría (≤5 °C)	193	9.388	48,6	25
Templada (5-15 °C)	5.248	555.609	105,9	70
Cálida (15-25 °C)	6.103	1.160.028	190,1	150
Calurosa (>25 °C)	5.835	1.567.654	268,7	236

Nota. Elaboración propia. Rangos construidos sobre temp_c con cortes en 5, 15 y 25 °C.

5.5. Perfil de usuario

Los suscriptores son la mayor parte de la demanda: más de cuatro de cada cinco rentas corresponden a usuarios con suscripción. El reparto, sin embargo, cambia con el tipo de día: en los días no laborables el peso del usuario casual se multiplica por más de dos, hasta llegar a casi un tercio de las rentas. Es el hallazgo con la implicación operativa más directa, porque los dos perfiles no usan el sistema en los mismos momentos.

Tabla 14. Composición de la demanda por tipo de usuario

Tipo de usuario	Rentas	Participación	Promedio por hora
Casual	620.017	18,8 %	35,7
Registrado	2.672.662	81,2 %	153,8
Total	3.292.679	100,0 %	189,5

Nota. Elaboración propia. Promedio por hora calculado sobre las horas del periodo.

Tabla 15. Tipo de usuario según el tipo de día

Tipo de día	Casual	Registrado	Casual (%)	Registrado (%)
Laborable	303.285	1.989.125	13,2 %	86,8 %
No laborable	316.732	683.537	31,7 %	68,3 %

Nota. Elaboración propia. Porcentajes calculados dentro de cada tipo de día.

5.6. Concentración de la operación y días de mayor demanda

Una hora mediana representa alrededor del 3,7 % de la renta de su día, pero el máximo llega al 100 %: corresponde a días con una sola hora registrada. Por eso la participación horaria se interpreta junto con la cantidad de horas del día y no de forma aislada. Los días de mayor demanda del periodo se concentran en septiembre de 2012, con más de 8.300 rentas diarias.

Tabla 16. Distribución de la participación de una hora dentro de su día

Estadístico	Participación (%)
Registros	17.379,00
Media	4,21
Desviación	3,47
Mínimo	0,01
Percentil 25	1,24
Mediana	3,66
Percentil 75	6,34
Máximo	100,00

Nota. Elaboración propia. Porcentaje que representa cada hora dentro del total de su día.

Tabla 17. Días de mayor demanda del periodo

Fecha	Rentas del día	Horas registradas
2012-09-15	8.714	24
2012-09-29	8.555	24
2012-09-22	8.395	24
2012-03-23	8.362	24
2012-05-19	8.294	24

Nota. Elaboración propia. Los cinco días con más rentas del periodo.

5.7. Discusión: qué dicen los resultados para la operación

Leídos en conjunto, los resultados describen una demanda predecible en su forma: se concentra en dos picos, depende del calendario laboral, cae con el mal tiempo y está sostenida por los suscriptores. Para el área de operaciones eso significa que la asignación de bicicletas y de personal de redistribución debería seguir la franja horaria y no el promedio diario, y que la madrugada es la ventana natural para el mantenimiento, porque es cuando menos se usa el sistema.

El peso del usuario casual en los días no laborables sugiere una operación distinta para esos días: la demanda no solo cambia de magnitud, cambia de perfil. También conviene distinguir entre el promedio y la mediana al fijar metas, porque el promedio del día no laborable se parece al del laborable aunque su comportamiento típico sea menor.

Estos resultados son descriptivos. No permiten afirmar que aumentar la flota o mover bicicletas entre zonas vaya a modificar la demanda, ni estimar el efecto de una tarifa o de una campaña: para eso haría falta un diseño causal o un experimento, que quedan fuera del alcance. Tampoco se puede hablar de rentabilidad, porque el dataset no contiene costos, precios ni información de flota.

5.8. Limitaciones de los resultados

- La unidad es la hora del sistema completo: no hay estaciones, trayectos ni usuarios individuales, así que no se puede describir la oferta ni el origen y destino de los viajes.

- Faltan 165 horas de las 17.544 esperadas, repartidas en 76 días incompletos; los promedios de esos días se calculan sobre las horas disponibles.
- La condición de tormenta tiene tres registros: su promedio no es representativo.
- La comparación entre 2011 y 2012 está afectada por el crecimiento del sistema durante el periodo, que los datos no documentan.
- Los datos cubren una sola ciudad y dos años: no se pueden generalizar a otros sistemas ni a años posteriores.

6. Conclusiones del avance

El dataset quedó preparado y documentado: ocho reglas de transformación con su efecto registrado, doce variables nuevas y un DataFrame final de 40 columnas que conserva las 17.379 filas originales. Ninguna regla eliminó registros ni imputó valores, y la unión con la tabla diaria se validó sin duplicar filas ni alterar el total de rentas.

- La demanda no se reparte de forma uniforme: el pico de la tarde concentra un tercio de las rentas y la madrugada apenas una fracción mínima. La operación debería dimensionarse por franja.
- El tipo de día cambia la composición más que el promedio: en días no laborables el usuario casual pasa de 13,2 % a 31,7 % de las rentas.
- El clima separa con claridad los niveles de demanda (despejado frente a lluvia), mientras que la tormenta no tiene registros suficientes para concluir.
- Los suscriptores sostienen el sistema con más de cuatro quintas partes de las rentas, pero el perfil ocasional es el que explica la diferencia entre días.
- La comparación entre años no es concluyente por sí sola: el crecimiento del sistema se mezcla con la estacionalidad y con la composición de meses de cada archivo.

Queda pendiente la representación gráfica de estos resultados y el cálculo de los indicadores de la etapa de métricas, que se apoyarán en las tablas y en el dataset preparado que esta entrega deja en el repositorio. También queda pendiente profundizar en la comparación mes a mes entre años, que permitiría separar el crecimiento del sistema del efecto estacional.

7. Referencias

Callejas Jaramillo, A. F. (2026). Material de clase y encuentros sincrónicos de Proyecto Integrado III - Analítica de Datos. Institución Universitaria Digital de Antioquia.

Fanaee-T, H. y Gama, J. (2013). Event labeling combining ensemble detectors and background knowledge. Progress in Artificial Intelligence, pp. 1-15. Springer Berlin Heidelberg. https://doi.org/10.1007/s13748-013-0040-3

Hugging Face. (2026). t22000t/bike-sharing-tabular [Dataset]. Recuperado el 24 de octubre de 2026 de https://huggingface.co/datasets/t22000t/bike-sharing-tabular

McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt y J. Millman (Eds.), Proceedings of the 9th Python in Science Conference (pp. 56-61).

Provost, F. y Fawcett, D. (2013). Data science for business: what you need to know about data mining and data-analytic thinking. O'Reilly Media.

The pandas development team. (2026). pandas documentation. Recuperado el 24 de octubre de 2026 de https://pandas.pydata.org/docs/

UCI Machine Learning Repository. (s. f.). Bike Sharing Dataset (id 275). University of California, Irvine. Recuperado el 24 de octubre de 2026 de https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset

8. Anexo. Evidencias y rutas del repositorio

Todas las evidencias de la etapa están publicadas en el repositorio del proyecto y se regeneran al ejecutar el notebook desde cero. La tabla siguiente indica dónde se encuentra cada una.

Tabla 18. Evidencias de la etapa 2 y su ubicación en el repositorio

Evidencia	Contenido	Ruta
Notebook	Transformación, enriquecimiento, resultados y exportaciones	AE3/notebooks/ EA3_transformacion_enriquecimiento.ipynb
Clases del proceso	TransformadorBikes y EnriquecedorBikes	src/clases_po/transformador.py y enriquecedor.py
Clase de reporte	Reportes: .txt descriptivo del DataFrame final	src/clases_po/reportes.py
Dataset preparado	DataFrame final en CSV (17.379 × 40)	AE3/datos/dataset_preparado.csv
Tablas de resultados	Doce tablas de resultados y cuatro de control	AE3/resultados/tabla_*.csv
Reporte descriptivo	Filas, columnas, tipos, nulos y estadísticas	AE3/resultados/resumen_dataframe.txt
Documento	Este informe en .docx y .pdf	AE3/documento/

Nota. Repositorio: https://github.com/carlososoa/proyecto-integrado-iii

Para reproducir la entrega basta con ejecutar, desde la carpeta del notebook, el comando jupyter nbconvert --to notebook --execute --inplace EA3_transformacion_enriquecimiento.ipynb. Las rutas de salida son relativas y los archivos se regeneran en cada ejecución.