Guía del equipo — todo lo que hay que saber para presentar la AE4

Grupo AE_Grupo 3 · Estefanía Martínez Guzmán · Carlos Andrés Osorio Agudelo · Valentina Pérez Flórez

Curso: Proyecto Integrado III — Analítica de Datos · Docente: Andrés Felipe Callejas Jaramillo

> *Esta guía está escrita para leerse en 15 minutos y poder responder cualquier pregunta del profesor sobre los datos y el proceso. Si algo no queda claro, preguntar antes del martes 17.*

1. El proyecto en una página

Un sistema de bicicletas públicas necesita saber **cuándo se usa más y bajo qué condiciones**, porque de eso dependen tres decisiones de operación:

1. **Cuántas bicicletas** hay disponibles en cada zona.
2. **Cuántas personas** se necesitan para reubicar bicicletas entre estaciones.
3. **Cuándo** hacer el mantenimiento sin afectar el servicio.

El dataset no trae esa lectura hecha. El proyecto toma los datos crudos del sistema, los limpia, los enriquece y construye métricas que responden **seis preguntas de negocio**. La evidencia final es una aplicación en Streamlit que cualquiera puede abrir y recorrer.

Alcance: el análisis es **descriptivo y comparativo**. No explica causas ni predice valores futuros. Esa frase hay que decirla tal cual si el profesor pregunta por el alcance.

2. El dataset, explicado sin jerga

Dato	Valor
Fuente	UCI Machine Learning Repository, *Bike Sharing Dataset* (id 275), vía Hugging Face t22000t/bike-sharing-tabular
Sistema real	**Capital Bikeshare**, Washington D. C.
Periodo	1 de enero de 2011 – 31 de diciembre de 2012
Registros	**17.379 horas** (de 17.544 posibles)
Columnas originales	17
Columnas después del enriquecimiento	40

La idea clave: una fila = una hora

Cada fila no es un cliente ni un viaje: es **una hora de operación** del sistema, con la cantidad de bicicletas que se rentaron en esa hora y cómo estaban el clima y el calendario.

Las variables que hay que saber sí o sí

Variable	Qué significa	Unidad / valores
cnt	Rentas totales de esa hora	conteo (entero)
casual	Rentas de usuarios sin suscripción	conteo
registered	Rentas de usuarios con suscripción	conteo
hr	Hora del día	0 a 23
workingday / holiday	Si es día laborable / festivo	0 o 1
season	Temporada	1 primavera, 2 verano, 3 otoño, 4

		invierno
weathersit	Condición del clima	1 despejado … 4 lluvia fuerte
temp, hum, windspeed	Temperatura, humedad, viento (venían normalizados 0–1)	convertidos a °C, %, km/h
yr	Año	0 = 2011, 1 = 2012

Regla que siempre se cumple: cnt = casual + registered en los 17.379 registros.

Si el profesor pregunta cómo se validó, esa es la primera respuesta.

Qué es "enriquecer" (etapa 2)

No se agregaron filas ni fuentes externas: se **construyeron 12 variables nuevas** a partir de las

que ya existían. Ejemplos:

- franja_horaria: agrupa las 24 horas en 6 franjas (madrugada, mañana, pico mañana, mediodía, pico tarde, noche).
- tipo_dia: laborable o no laborable, combinando workingday y holiday.
- temp_c, hum_pct, windspeed_kmh: las escalas originales pasadas a unidades entendibles.
- total_dia, promedio_hora_dia, pct_hora_del_dia: contexto del día para comparar una hora contra su propio día.

Calidad de los datos (lo que sí se corrigió y lo que no)

- 0 duplicados de hora, 0 inconsistencias entre cnt y casual + registered.
- **165 horas faltantes en 76 días** (≈ 0,9 % del periodo). **No se imputaron**: se declaran como

limitación. Responder así si preguntan por datos faltantes.

3. Qué se entregó en cada etapa

Etapa	Qué hicimos	Evidencia en el repositorio
EA1	Cargar el dataset y describir su estructura	EA1/notebooks/, EA1/resultados/resumen_dataset.txt
AE2	Definir la necesidad, las preguntas y revisar la calidad (tipos, nulos, dominios)	AE2/documento/, AE2/notebooks/
AE3	Transformar, enriquecer y generar las **17 tablas de resultados**	AE3/notebooks/, AE3/resultados/*.csv, dataset_preparado.csv
AE4	Métricas, app en Streamlit y documento integral	AE4/app.py, AE4/metricas.py

Aplicación publicada: <https://proyecto-integrado-iii-team3-preica2602b020038.streamlit.app/>

Un solo repositorio para todo el periodo: **https://github.com/carlososoa/proyecto-integrado-iii**

4. Las seis preguntas y su respuesta (con la cifra)

Estas cifras son del periodo completo (2011–2012). En la app cambian si se aplican filtros.

#	Pregunta	Respuesta en una frase	Cifra clave
1	¿Cuánta demanda hay y cómo se reparte en el día?	3.292.679 rentas en 17.379 horas; promedio 189,5 por hora y mediana 142, así que	189,5 vs 142

		hay horas muy cargadas y muchas flojas.	
2	¿En qué franjas horarias se concentra?	La tarde concentra la demanda: "pico tarde" (16–19 h) aporta 33,4 % del total. La madrugada solo 3,2 %.	33,4 %
3	¿Cambia según el tipo de día?	El laborable promedia 193,2 rentas/hora y el no laborable 181,4, pero el perfil es distinto: el laborable tiene dos picos (entrada y salida del trabajo). El ocasional pasa de 13,2 % a 31,7 %.	13,2 % → 31,7 %
4	¿Cambia con la temporada y entre años?	Otoño es la temporada más fuerte (236,0 rentas/hora) y primavera la más floja (111,1). El promedio creció 63 % de 2011 a 2012, en las cuatro temporadas.	+63 %
5	¿Cambia con el clima y la temperatura?	Con cielo despejado 204,9 rentas/hora; con lluvia o nieve ligera 111,6: cae 45,5 %. La demanda sube al pasar de frío a templado.	−45,5 %
6	¿Qué peso tienen casuales y registrados?	El registrado concentra 81,2 % de las rentas (2.672.662) y el casual 18,8 % (620.017). El casual crece los fines de semana.	81,2 % / 18,8 %

Frase de cierre del análisis: la demanda es **predecible en su forma** (franja horaria, tipo de día, clima) y **creciente en su volumen** (2012 sobre 2011), lo que permite planear operación, pero el dataset **no permite afirmar causas** ni proyectar años futuros.

5. Cómo se usa la app (recorrido para la demo)

La aplicación tiene nueve secciones y con eso se puede hacer **toda la presentación sin diapositivas**:

4. **Proyecto y datos** (apertura): necesidad, pregunta de análisis, alcance y ficha del dataset.
5. **Resumen del periodo**: gráfico de demanda promedio por hora + participación por franja + tabla de las seis preguntas.
6. **Filtros (barra izquierda)**: periodo, temporada, tipo de día y clima. Todo se recalcula.
7. **Preguntas 1 a 6**: cada una muestra la métrica con su unidad, el gráfico, la lectura, la decisión que apoya y la limitación.
8. **Tablas desplegables**: cada sección tiene la tabla exacta de respaldo (las mismas cifras del documento).
9. **Conclusiones y recomendaciones** (cierre): cuatro tarjetas de conclusión, cinco recomendaciones y el bloque de lo que el análisis no afirma.

Demostración sugerida para los 5 minutos: apertura (30 s) → resumen (30 s) → pregunta 2 con filtro a "No laborable" (40 s) → pregunta 5 cambiando el clima (30 s) → pregunta 6 (30 s) → cierre en conclusiones (1 min).

6. Preguntas que puede hacer el profesor (y cómo responder)

Pregunta	Respuesta corta

¿Por qué ese dataset?	Porque trae la variable que se quiere describir (cnt) y los criterios para compararla (hora, tipo de día, temporada, clima), en un registro horario real de dos años.
¿Los datos son reales?	Sí: registro horario del sistema Capital Bikeshare (Washington D. C.), publicado en UCI y replicado en Hugging Face.
¿Qué es una fila?	Una hora de operación del sistema, no un viaje ni un cliente.
¿Cómo validaron los datos?	cnt = casual + registered en los 17.379 registros; 0 duplicados de hora; 40 columnas documentadas y verificadas contra el dataframe.
¿Qué hicieron con los datos faltantes?	Son 165 horas de 76 días (0,9 %). No se imputan: se declaran como limitación porque inventar horas alteraría los promedios.
¿Por qué promedio y mediana?	Porque si el promedio (189,5) está muy por encima de la mediana (142), la distribución tiene horas muy cargadas: la mediana describe la hora típica, el promedio el volumen.
¿Eso es causalidad?	No. Es descriptivo y comparativo: se observa que con lluvia baja la demanda, pero clima y temporada se mueven juntos, así que no se aísla la causa.
¿Por qué Streamlit?	Porque se conecta al mismo repositorio, lee los datos preparados y publica una URL accesible; el profesor puede revisarla sin instalar nada.
¿Qué limitación tiene el análisis?	Tres: no hay capacidad instalada (no se mide demanda insatisfecha), no hay usuarios únicos (registrado/casual son tipos de renta, no personas) y solo hay dos años, insuficiente para proyectar.
¿Qué decisión se puede tomar con esto?	Reforzar flota y personal en el pico de la tarde (16–19 h), programar mantenimiento en la madrugada, y ajustar la operación según el clima y el tipo de día.
¿Qué cambiarían con más datos?	Agregar capacidad por estación y datos de usuarios para separar efecto clima de efecto temporada, y más años para proyectar.

7. Reparto del guion (5 minutos + 5 de preguntas)

Minuto	Quién	Qué dice
0:00 – 1:00	Estefanía	Necesidad, pregunta de negocio y qué representa una fila del dataset
1:00 – 3:30	Carlos	Demo en la app: resumen, filtros y preguntas 1 a 3 (con las cifras)
3:30 – 4:30	Valentina	Preguntas 4 a 6: temporada, clima y tipo de usuario
4:30 – 5:00	Estefanía	Conclusiones, recomendaciones y limitaciones

Cada integrante debe poder responder por **cualquier** pregunta: el profesor ya avisó que pregunta a un integrante qué hizo el otro.

8. Reglas y fechas (lo que dijo el profesor)

- **Presentación: martes 17 de noviembre, 7:20 – 7:30 p. m.** (semana 7). Conectarse 6:45 p. m. al Meet del sincrónico.
- **Formato: 5 min de presentación + 5 min de preguntas.** Es obligatorio presentar: la nota se entrega al final de la clase.
- **Todos los integrantes participan** y deben conocer el proceso.

- **Entrega en Canvas: domingo 29 de noviembre, 11:59 p. m.** con el PDF completo y los enlaces del repositorio y de la app.
- La app gratuita **se duerme por inactividad**: hay que abrirla 10 minutos antes de presentar.